

Módulo III - Fundamentos de Machine Learning

Proyecto ML - Clasificación



Considerando la base de datos de Iris-plant en la página de uci machine learning
<https://archive.ics.uci.edu/>

1. Descripción de los atributos

*Debe describir cada uno de los atributos al momento (si son mas de 10, solo describir 10),
Indicando:*

a. Tipo Dato (numérico, categórico)

i. En caso de ser numérico, min, max, promedio y desviación estándar globales

ii. En caso de ser categórico, las categorías

R =

La base de datos consiste en mediciones de 150 flores de Iris con 5 atributos, por lo tanto, la restricción de describir solo 10 atributos NO APLICA en el caso de la base de datos utilizada.

Categorías del atributo [4] (clase):

- Iris-setosa
 - Iris-versicolor
 - Iris-virginica
-

Atributo	Nombre	Tipo	Min	Max	Promedio	Desviación Estándar
0	Longitud del sépalo	Númérico	4.30	7.90	5.84	0.83
1	Ancho del sépalo	Númérico	2.00	4.40	3.05	0.43
2	Longitud del pétalo	Númérico	1.00	6.90	3.76	1.76
3	Ancho del pétalo	Númérico	0.10	2.50	1.20	0.76
4	Especie (clase)	Categorico	NA	NA	NA	NA

```

Run KNN clase cd 2026 08 22 x proyectoFinal x
/Users/iseicq/dev/Moulo3_IA/.venv/bin/python /Users/iseicq/dev/Moulo3_IA/Proyecto/proyectoFinal.py
Atributo 0: CUANTITATIVO
Atributo 1: CUANTITATIVO
Atributo 2: CUANTITATIVO
Atributo 3: CUANTITATIVO
Atributo 4: CUALITATIVO
Categorías del atributo 4: ['Iris-virginica', 'Iris-setosa', 'Iris-versicolor']
Atributo 0 ---> Promedio = 5.8433, Min = 4.3000, Max = 7.9000, Desviación Estándar = 0.8253.
Atributo 1 ---> Promedio = 3.0540, Min = 2.0000, Max = 4.4000, Desviación Estándar = 0.4321.
Atributo 2 ---> Promedio = 3.7587, Min = 1.0000, Max = 6.9000, Desviación Estándar = 1.7585.
Atributo 3 ---> Promedio = 1.1987, Min = 0.1000, Max = 2.5000, Desviación Estándar = 0.7606.

```

Fig. 1: Salida de la consola mostrando "Atributo[j] : CUANTITATIVO / CUALITATIVO" y "Estadísticas de los atributos"

2. Definición de V_x y V_y

Definir los atributos del vector de entrada X y de salida (clase) Y

a. Por cada clase obtener:

- Max, min, promedio y desviación estándar de cada uno de los atributos en el vector de entrada
- Las categorías en caso de los datos categóricos

R =

- Vector de entrada ----> $V_x = [0, 1, 2, 3] \text{ ----> } [LS, AS, LP, AP]$

- Vector de salida ----> $V_y = [4] \text{ ----> } 'Iris-setosa', 'Iris-versicolor', 'Iris-virginica'$

```
Run KNN clase cd 2026 08 22 x proyectoFinal x
[[6.9, 3.1, 5.1, 2.3], ['Iris-virginica']]
[[5.8, 2.7, 5.1, 1.9], ['Iris-virginica']]
[[6.8, 3.2, 5.9, 2.3], ['Iris-virginica']]
[[6.7, 3.3, 5.7, 2.5], ['Iris-virginica']]
[[6.7, 3.0, 5.2, 2.3], ['Iris-virginica']]
[[6.3, 2.5, 5.0, 1.9], ['Iris-virginica']]
[[6.5, 3.0, 5.2, 2.0], ['Iris-virginica']]
[[6.2, 3.4, 5.4, 2.3], ['Iris-virginica']]
[[5.9, 3.0, 5.1, 1.8], ['Iris-virginica']]
Clases (Y): ['Iris-setosa', 'Iris-versicolor', 'Iris-virginica']
LS --> Promedio = 5.8433, Min= 4.3000, Max= 7.9000, Desviación Estándar= 0.8253.
AS --> Promedio = 3.0540, Min= 2.0000, Max= 4.4000, Desviación Estándar= 0.4321.
LP --> Promedio = 3.7587, Min= 1.0000, Max= 6.9000, Desviación Estándar= 1.7585.
AP --> Promedio = 1.1987, Min= 0.1000, Max= 2.5000, Desviación Estándar= 0.7606.
```

Fig. 2: Respuesta en consola del cálculo de estadísticas del vector de entrada (x) y categorías por clase

3. Preprocesamiento

En caso de ser necesario hacer un preprocesamiento a la base de datos, describirlo

R =

La base de datos Iris no requirió de pre-procesamiento para poder utilizarse ya que no tiene filas vacías, no hay valores faltantes y las 4 variables de entrada tienen rangos de magnitud similares que no distorsiona los cálculos.

4. Clasificador KNN (Train & Test)

Obtener las métricas de recuperación (% aciertos) y error del clasificador K-NN usando el método de validación de tu elección

R =


KNN:

Clasificador basado en distancias matemáticas - en este caso distancias Euclidianas. Consiste en almacenar las muestras de entrenamiento y calcular su distancia a todas las muestras aprendidas, se toman las K más cercanas y se asigna la clase mayoritaria.

Train & Test:

70% entrenamiento / 30% prueba, dividido balanceado por clase (35 por clase para entrenar, 15 por clase para probar).


k = 3 ---->



```
Run KNN clase cd 2026 08 22 x proyectoFinal x
AS --> Promedio = 3.0540, Min= 2.0000, Max= 4.4000, Desviación Estándar= 0.4321.
LP --> Promedio = 3.7587, Min= 1.0000, Max= 6.9000, Desviación Estándar= 1.7585.
AP --> Promedio = 1.1987, Min= 0.1000, Max= 2.5000, Desviación Estándar= 0.7606.
Número de vecinos a considerar (K): 3
MÉTRICAS DE RECUPERACIÓN DEL CLASIFICADOR K-NN
TRAIN AND TEST (70% entrenamiento, K=3)
Muestras de entrenamiento: 105
Muestras de prueba: 45
Aciertos: 45 de 45
Recuperación (% aciertos): 100.00%
Error: 0.00%
```

Fig. 4.1: Métricas de recuperación KNN Train & Test, K=3 y 100% de recuperación

k = 7 ---->



```
Run KNN clase cd 2026 08 22 x proyectoFinal x
AS --> Promedio = 3.0540, Min= 2.0000, Max= 4.4000, Desviación Estándar= 0.4321.
LP --> Promedio = 3.7587, Min= 1.0000, Max= 6.9000, Desviación Estándar= 1.7585.
AP --> Promedio = 1.1987, Min= 0.1000, Max= 2.5000, Desviación Estándar= 0.7606.
Número de vecinos a considerar (K): 7
MÉTRICAS DE RECUPERACIÓN DEL CLASIFICADOR K-NN
TRAIN AND TEST (70% entrenamiento, K=7)
Muestras de entrenamiento: 105
Muestras de prueba: 45
Aciertos: 44 de 45
Recuperación (% aciertos): 97.78%
Error: 2.22%
```

Fig. 4.2: Métricas de recuperación KNN Train & Test, K=7 y 97.78% de recuperación

5. Clasificador Mínima Distancia (Train & Test)

Obtener las métricas de recuperación (% aciertos) y error del clasificador de mínima distancia usando el método de validación de tu elección

R =

Mínimas distancia :

Este clasificador resume cada clase en un solo representante: su centroide - el promedio de todas las muestras aprendidas de esa clase. Se calcula la distancia entre el centroide y la muestra Z, se asigna la clase del centroide más cercano.

Train and Test: 70% / 30% misma división balanceada por clase que el punto anterior.

La mínima distancia, en comparación con KNN k=3 |100% , fue ligeramente menos precisa (95.56%) porque al representar cada clase con un único centroide, las muestras cercanas a la frontera entre clases tienden a confundirse.

```

Run KNN clase cd 2026 08 22 x proyectoFinal x
CENTROIDES APRENDIDOS POR CLASE
Iris-setosa: [5.0457, 3.4686, 1.4771, 0.24]
Iris-versicolor: [6.0086, 2.7686, 4.3143, 1.3429]
Iris-virginica: [6.6171, 2.9371, 5.6257, 1.9771]
o+*.~(.~*~+
MÉTRICAS DE RECUPERACIÓN DEL CLASIFICADOR DE MÍNIMA DISTANCIA
TRAIN AND TEST (70% entrenamiento)
o+*.~(.~*~+
Muestras de entrenamiento: 105
Muestras de prueba: 45
Aciertos: 43 de 45
Recuperación (% aciertos): 95.56%
Error: 4.44%
o+*.~(.~*~+

```

Fig. 5: Métricas de recuperación Mínima distancia Train & Test, 95.56% de recuperación

6. Eliminación de atributos

Elegir dos de los atributos utilizando algún criterio o razón que debe describir por la que se cree que su eliminación puede mejorar la eficiencia y posteriormente:

- Eliminar uno de los dos atributos elegidos y corroborar la teoría mediante los 3 métodos de validación vistos*
- Eliminar el otro de los atributos elegidos y corroborar la teoría mediante los 3 métodos de validación vistos*
- Eliminar los dos atributos elegidos y corroborar la teoría mediante los 3 métodos de validación vistos*

R =

Hipótesis:

Quitar LP y AP no perjudica significativamente la precisión porque el conjunto de datos presenta una varianza alta, lo que nos indica que los valores están dispersos y lejos de la media; por lo que LS y AS (con varianza baja) nos ayudarían a compensar la precisión del clasificador.

	KNN	Mínima Distancia
4 atributos	100 %	95.56 %
Sin LP	97.78 %	95.11 %
Sin AP	95.56 %	91.11 %
Sin LP & AP	75.56 %	88.89 %

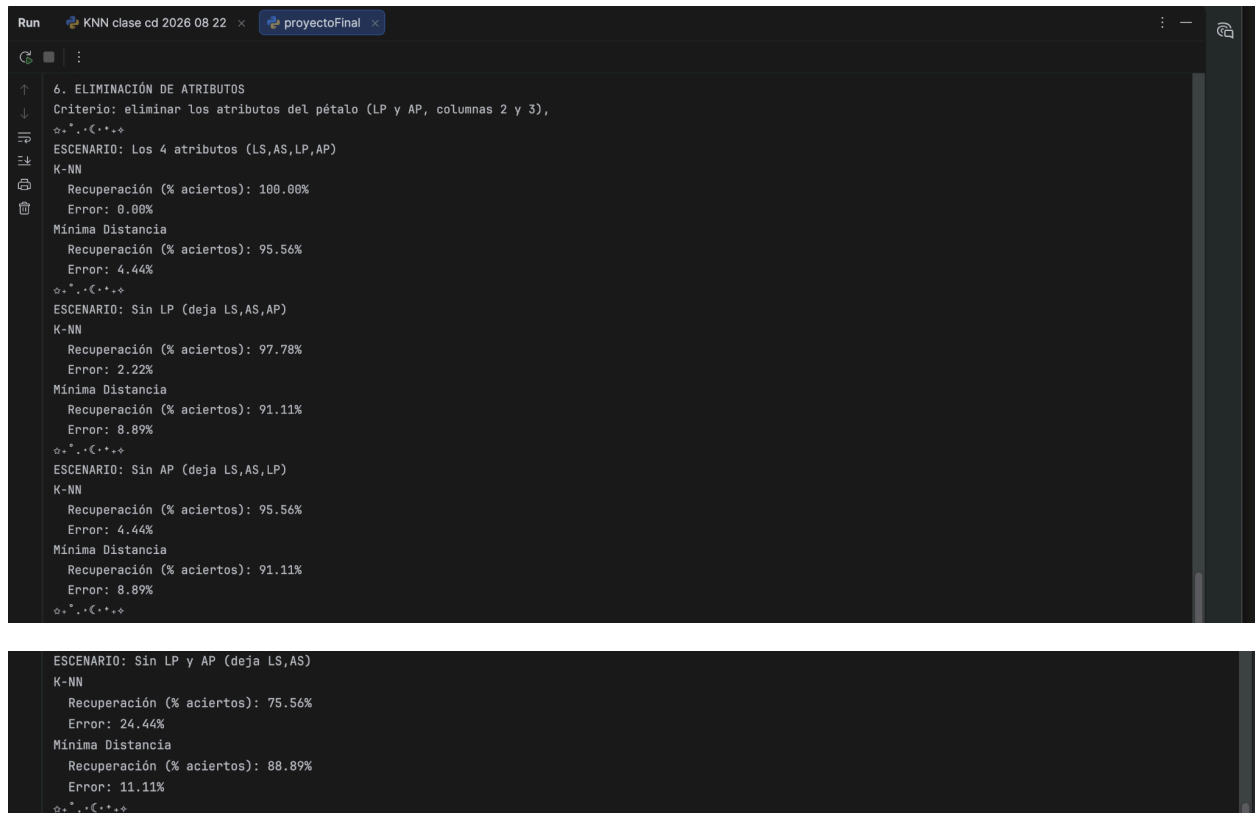
La hipótesis se rechaza:

La hipótesis es rechazada por los datos, la precisión no se mantuvo. Al eliminar ambos atributos la precisión bajó de 100% a 75.56%.

Conclusión:

Lo que determina la contribución de un atributo no es su varianza “alta” si no su discriminabilidad; es decir, su capacidad de separar las clases.

Los atributos del pétalo separan a las tres especies de Iris, mientras que los del sépalo se traslapan ampliamente entre Iris- setosa e Iris-versicolor, por lo que no pueden compensar que se eliminen los atributos del pétalo.



```
Run KNN clase cd 2026 08 22 x proyectoFinal x
6. ELIMINACIÓN DE ATRIBUTOS
Criterio: eliminar los atributos del pétalo (LP y AP, columnas 2 y 3),
+-+..+-+
ESCENARIO: Los 4 atributos (LS,AS,LP,AP)
K-NN
  Recuperación (% aciertos): 100.00%
  Error: 0.00%
Mínima Distancia
  Recuperación (% aciertos): 95.56%
  Error: 4.44%
+-+..+-+
ESCENARIO: Sin LP (deja LS,AS,AP)
K-NN
  Recuperación (% aciertos): 97.78%
  Error: 2.22%
Mínima Distancia
  Recuperación (% aciertos): 91.11%
  Error: 8.89%
+-+..+-+
ESCENARIO: Sin AP (deja LS,AS,LP)
K-NN
  Recuperación (% aciertos): 95.56%
  Error: 4.44%
Mínima Distancia
  Recuperación (% aciertos): 91.11%
  Error: 8.89%
+-+..+-+

ESCENARIO: Sin LP y AP (deja LS,AS)
K-NN
  Recuperación (% aciertos): 75.56%
  Error: 24.44%
Mínima Distancia
  Recuperación (% aciertos): 88.89%
  Error: 11.11%
+-+..+-+
```

Fig. 6.1 y 6.2: Resultados de la eliminación de atributos y sus distintos escenarios.

7. Error en la unidad de medida


Suponga que por error en la unidad de medida, algunas de las muestras de aprendizaje en lugar de cm, se registraron en mm. Para ejemplificar esto reemplaza 3 de las muestras usadas en el aprendizaje por las siguientes y obtén los porcentajes de recuperación y error usando los clasificadores 1-NN, 3-NN, 7-NN y mínima distancia. Explica las diferencias en los resultados.

Num muestra	LS	AS	LP	AP	Clase
1	50	35	14	20	Iris-setosa
2	50	35	14	20	Iris-setosa
3	50	32	13	20	Iris-setosa

R =

El KNN no se ve afectado por los valores atípicos porque se encuentran muy lejos de las muestras reales de la prueba, así que no participan entre los K vecinos más cercanos.

En cambio, con la Mínima Distancia si se ve un afectado el % de recuperación, ya que al incluir los valores anómalos el centroide se desplaza considerablemente (x10) haciendo que la clasificación de la clase se vea contaminada. Muchas de las Iris-setosa quedan mal clasificadas.



```
Run KNN clase cd 2026 08 22 x proyectoFinal x
7. SUSTITUCIÓN DE 3 MUESTRAS EN EL CONJUNTO DE APRENDIZAJE
Antes de sustituir (primeras 3 muestras del aprendizaje):
[[5.1, 3.5, 1.4, 0.2], ['Iris-setosa']]
[[4.9, 3.0, 1.4, 0.2], ['Iris-setosa']]
[[4.7, 3.2, 1.3, 0.2], ['Iris-setosa']]
Después de sustituir (primeras 3 muestras del aprendizaje):
[[50.0, 35.0, 14.0, 20.0], ['Iris-setosa']]
[[50.0, 35.0, 14.0, 20.0], ['Iris-setosa']]
[[50.0, 32.0, 13.0, 20.0], ['Iris-setosa']]
```

Fig. 7.1: Muestra con nuevos valores.

```
Run KNN clase cd 2026 08 22 x proyectoFinal x
K = 1-NN (con muestras sustituidas)
Muestras de prueba: 45
Aciertos: 45 de 45
Recuperación (% aciertos): 100.00%
Error: 0.00%
K = 3-NN (con muestras sustituidas)
Muestras de prueba: 45
Aciertos: 45 de 45
Recuperación (% aciertos): 100.00%
Error: 0.00%
K = 5-NN (con muestras sustituidas)
Muestras de prueba: 45
Aciertos: 45 de 45
Recuperación (% aciertos): 100.00%
Error: 0.00%
```

Fig. 7.2: Resultados de la clasificación por KNN con 3 primeras muestras sustituidas

```
Run KNN clase cd 2026 08 22 x proyectoFinal x
Aciertos: 45 de 45
Recuperación (% aciertos): 100.00%
Error: 0.00%
Mínima Distancia (con muestras sustituidas)
Muestras de prueba: 45
Aciertos: 28 de 45
Recuperación (% aciertos): 62.22%
Error: 37.78%
Process finished with exit code 0
```

Fig. 7.2: Resultados de la clasificación por mínima distancia con 3 primeras muestras sustituidas